🏥 Health Eat — 경구약제 이미지 EDA & 전처리 전략

> **프로젝트**: 알약 이미지 객체 검출 (Object Detection)
> **평가 지표**: mAP@[0.75:0.95]

목차

1. 환경 설정 및 데이터 로드
2. 데이터셋 기본 현황
3. 폴더 구조 및 이미지 크기 확인
4. 어노테이션 로드 및 분석
5. 촬영 환경 분석
6. 이미지 시각화
7. 각도별 분석
8. 메타데이터 분석
9. 클래스 불균형 분석
10. 전처리 전략 및 증강 파이프라인
11. 모델링 팀 인계 요약

---

1. 환경 설정 및 데이터 로드

✅ 라이브러리 로드 완료

```
train 이미지 폴더 존재: True
test 이미지 폴더 존재 : True
어노테이션 폴더 존재  : True
```

---

2. 데이터셋 기본 현황

train/test 이미지 수, JSON 파일 수, 이미지-어노테이션 매칭 여부를 확인합니다.

```
train 이미지 수          : 232
test  이미지 수          : 842
JSON 파일 수             : 763
JSON stem 고유 개수      : 232
이미지 stem 고유 개수    : 232
이미지–JSON 매칭 개수    : 232
```

✅ 모든 이미지에 어노테이션 존재

---

3. 폴더 구조 및 이미지 크기 확인

어노테이션 폴더의 3단계 구조(세트 → 약 ID → JSON)를 파악하고,
모든 이미지의 해상도가 동일한지 확인합니다.

```
세트 폴더 수: 114

샘플 폴더명:
  K-001900-016548-019607-029451_json
    └── K-001900/
        ├── K-001900-016548-019607-029451_0_2_0_2_70_000_200.json
        ├── K-001900-016548-019607-029451_0_2_0_2_75_000_200.json
        └── K-001900-016548-019607-029451_0_2_0_2_90_000_200.json
    └── K-016548/
        ├── K-001900-016548-019607-029451_0_2_0_2_70_000_200.json
        ├── K-001900-016548-019607-029451_0_2_0_2_75_000_200.json
        └── K-001900-016548-019607-029451_0_2_0_2_90_000_200.json
  K-001900-016548-019607-033009_json
    └── K-001900/
        ├── K-001900-016548-019607-033009_0_2_0_2_70_000_200.json
        ├── K-001900-016548-019607-033009_0_2_0_2_75_000_200.json
        └── K-001900-016548-019607-033009_0_2_0_2_90_000_200.json
    └── K-016548/
        ├── K-001900-016548-019607-033009_0_2_0_2_70_000_200.json
        ├── K-001900-016548-019607-033009_0_2_0_2_75_000_200.json
        └── K-001900-016548-019607-033009_0_2_0_2_90_000_200.json
  K-001900-016548-021771-027926_json
    └── K-001900/
        ├── K-001900-016548-021771-027926_0_2_0_2_70_000_200.json
        ├── K-001900-016548-021771-027926_0_2_0_2_75_000_200.json
        └── K-001900-016548-021771-027926_0_2_0_2_90_000_200.json
    └── K-016548/
        ├── K-001900-016548-021771-027926_0_2_0_2_70_000_200.json
        ├── K-001900-016548-021771-027926_0_2_0_2_75_000_200.json
        └── K-001900-016548-021771-027926_0_2_0_2_90_000_200.json
```

> **결과**: 세트 폴더 114개 / 각 세트 안에 약 ID별 폴더 / 각 약마다 70·75·90도 JSON 3개씩

```
전체 이미지 수  : 232
고유 크기 종류  : 1

   width  height mode  count
0    976    1280  RGB    232
```

샘플 이미지 크기 확인 — 전체 976 × 1280 px 동일

K-003351-018357-038162_0_2_0_2_90_000_200.png
976 × 1280 px



K-003483-016232-020877-034597_0_2_0_2_70_000_200.png
976 × 1280 px



K-001900-016548-019607-033009_0_2_0_2_75_000_200.png
976 × 1280 px



> **결과**: 전체 이미지 976 × 1280 px로 통일 — 별도 리사이즈 기준 불필요

---

4. 어노테이션 로드 및 분석

분산된 JSON 파일들을 하나의 DataFrame으로 병합하고
클래스 분포, 이미지당 알약 수, 세트 구성 등을 분석합니다.

```
전체 어노테이션 수   : 763
고유 카테고리 수     : 56
고유 이미지 수       : 232
```

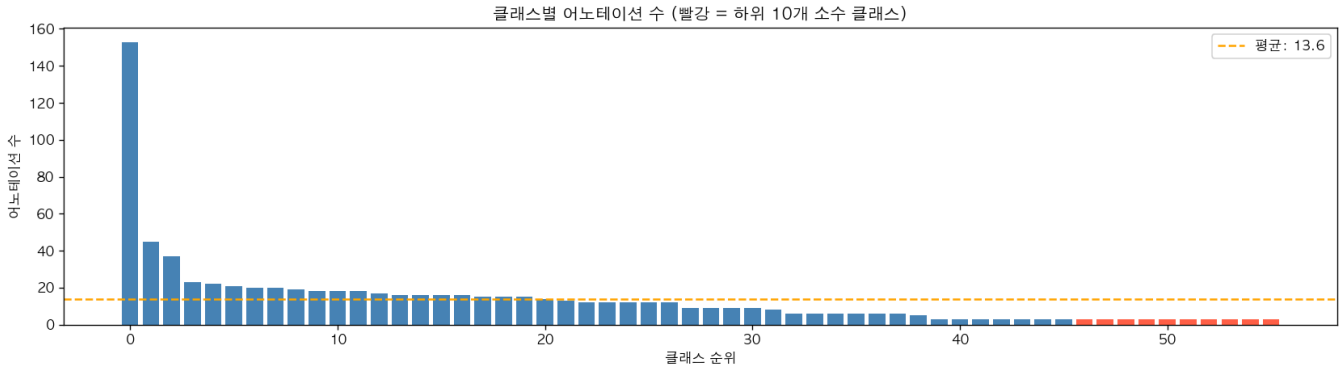
	category_id	category_name	image_id	bbox	area
0	1900	보령부스파정 5mg	34	[644, 845, 189, 190]	35910
1	1900	보령부스파정 5mg	35	[148, 241, 181, 181]	32761
2	1900	보령부스파정 5mg	36	[167, 248, 184, 182]	33488
3	16548	가바토파정 100mg	34	[144, 799, 239, 239]	57121
4	16548	가바토파정 100mg	35	[578, 222, 233, 226]	52658

📊 상위 5개 클래스 (데이터 많음):

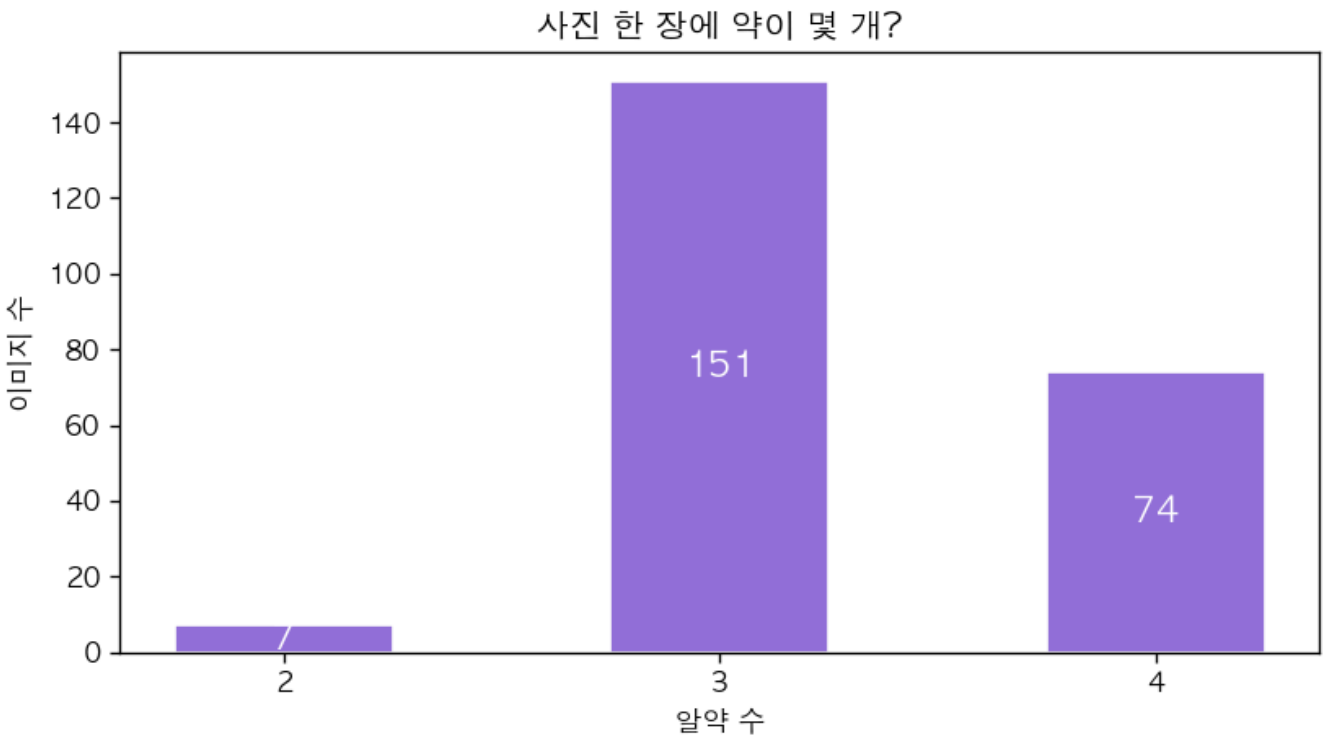
	category_id	category_name	num_annotations
0	3351	일양하이트린정 2mg	153
1	3483	기넥신에프정(은행엽엑스)(수출용)	45
2	35206	아토젯정 10/40mg	37
3	16262	크레스토정 20mg	23
4	21325	아토르바정 10mg	22

⚠️ 하위 5개 클래스 (데이터 부족):

	category_id	category_name	num_annotations
51	22362	맥시부펜이알정 300mg	3
52	13395	써스펜8시간이알서방정 650mg	3
53	16551	동아가바펜틴정 800mg	3
54	19552	트루비타정 60mg/병	3
55	21771	라비에트정 20mg	3



> **결과**: 1위 일양하이트린정 153개 vs 최하위 3개 → **최대 51배 불균형** — 클래스 가중치 필수



```
2      7
3    151
4     74
Name: count, dtype: int64
```

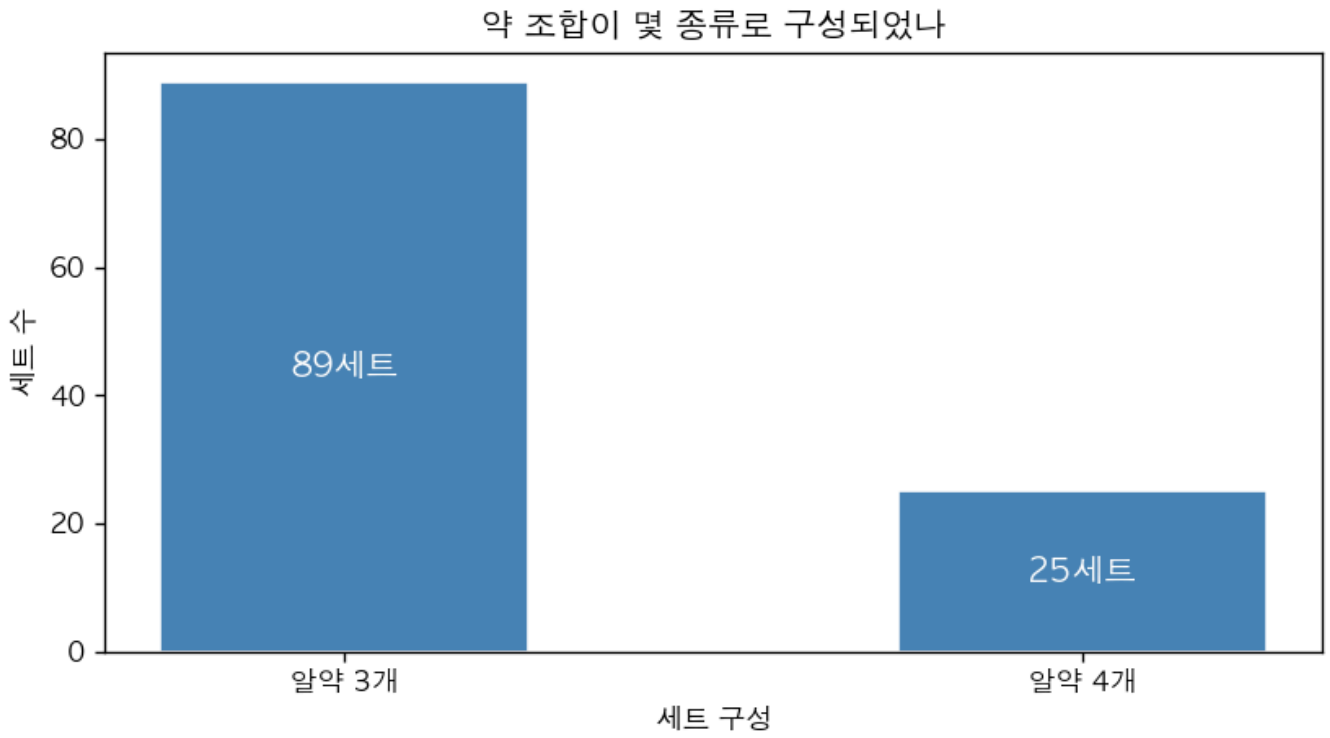
> **결과**: 대부분 이미지에 3~4개 알약 촬영 — 멀티 인스턴스 검출 모델 필요

전체 카테고리 목록 (빨강 = 소수 클래스 3개 이하)

카테고리 ID	약품명	어노테이션 수
3351	일양하이트린정 2mg	153
3483	기넥신에프정(은행엽엑스)(수출용)	45
35206	아토젯정 10/40mg	37
16262	크레스토정 20mg	23
21325	아토르바정 10mg	22
16232	리피토정 20mg	21
20238	플라빅스정 75mg	20
3832	뉴로메드정(목시라세탐)	20
36637	로수젯정10/5밀리그램	19
29667	리바로정 4mg	18
38162	로수바미브정 10/20mg	18
16548	가바토파정 100mg	18
19232	콜리네이트연질캡슐 400mg	17
22074	리피로우정 20mg	16
33880	글리틴정(콜린알포세레이트)	16
20014	마도파정	16
41768	카발린캡슐 25mg	16
18147	리리카캡슐 150mg	15
1900	보령부스파정 5mg	15
13900	에빅사정(메만틴염산염)(비매품)	15
32310	글리아타민연질캡슐	14
18357	종근당글리아티린연질캡슐(콜린알포세레이트)	13
27733	트윈스타정 40/5mg	12
25469	아모잘탄정 5/100mg	12
20877	엑스포지정 5/160mg	12
25367	자누메트정 50/850mg	12
31863	아질렉트정(라사길린메실산염)	12
22347	자누비아정 50mg	9
28763	트라젠타정(리나글립틴)	9
30308	트라젠타듀오정 2.5/850mg	9
2483	뮤테란캡슐 100mg	9
16688	오마코연질캡슐(오메가-3-산에틸에스테르90)	8
12778	다보타민큐정 10mg/병	6
25438	큐시드정 31.5mg/PTP	6
19861	노바스크정 5mg	6
19607	스토가정 10mg	6
29345	비모보정 500/20mg	6
3544	무코스타정(레바미피드)(비매품)	6
4543	에어탈정(아세클로페낙)	5
34597	제미메트서방정 50/1000mg	3
3743	알드린정	3
33208	에스원엠프정 20mg	3
33009	신바로정	3
31885	자누메트엑스알서방정 100/1000mg	3
12081	리렉스펜정 300mg/PTP	3
27777	카나브정 60mg	3
12247	아빌리파이정 10mg	3
29451	레일라정	3
27993	졸로푸트정 100mg	3
27926	울트라셋이알서방정	3
24850	놀텍정 10mg	3
22362	맥시부펜이알정 300mg	3
13395	써스펜8시간이알서방정 650mg	3
16551	동아가바펜틴정 800mg	3
19552	트루비타정 60mg/병	3
21771	라비에트정 20mg	3

```
세트당 알약 수 분포:
  알약 3개짜리 세트: 89개
  알약 4개짜리 세트: 25개

총 세트 수  : 114
최소 알약 수: 3
최대 알약 수: 4
```

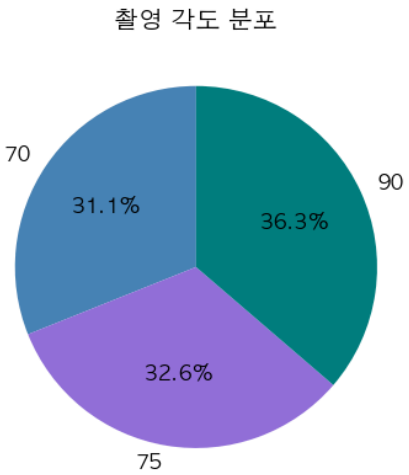


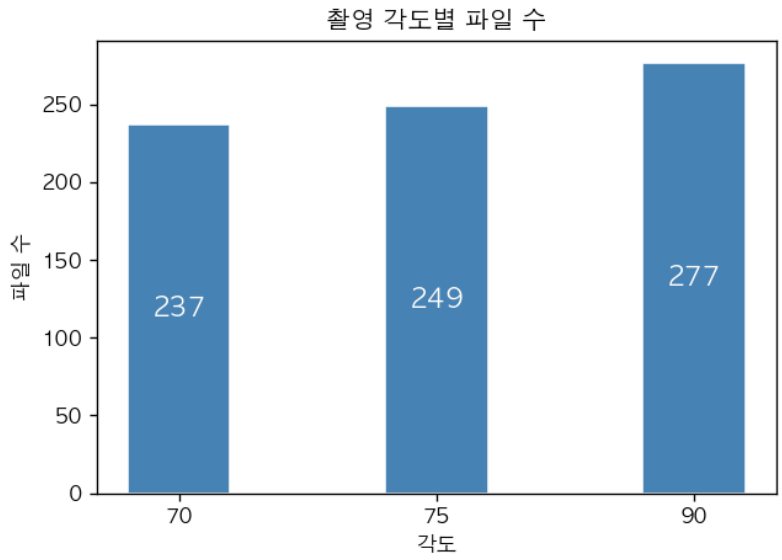
> **결과**: 3종 조합 89세트 / 4종 조합 25세트 — 이미지마다 알약 구성이 다름

---

5. 촬영 환경 분석

촬영 각도, 배경색, 조명 분포를 확인합니다.
편향된 환경이 확인되면 증강 전략에 반영합니다.





```
각도  파일 수
70   237
75   249
90   277
```

> **결과**: 70·75·90도 균등 분포 (각 약 33%씩)




```
배경색 분포:
back_color
연회색 배경    763
Name: count, dtype: int64

조명색 분포:
light_color
주백색    763
Name: count, dtype: int64
```

> ⚠️ **편향 확인**
>
> - 배경색 100% 연회색 → 배경 증강 필수
> - 조명색 100% 주백색 → Color Jitter 필수
> - 촬영 방향 98.4% 앞면, 1.6% 뒷면 → 뒷면 데이터 추가 수집 필요

```
뒷면 촬영 이미지 수: 12개

            약품명  각도                                                파일명
    일양하이트린정 2mg   70 K-003351-019232-029667_0_2_1_2_70_000_200.png
    일양하이트린정 2mg   90 K-003351-019232-029667_0_2_1_2_90_000_200.png
콜리네이트연질캡슐 400mg   70 K-003351-019232-029667_0_2_1_2_70_000_200.png
콜리네이트연질캡슐 400mg   90 K-003351-019232-029667_0_2_1_2_90_000_200.png
       리바로정 4mg   70 K-003351-019232-029667_0_2_1_2_70_000_200.png
       리바로정 4mg   90 K-003351-019232-029667_0_2_1_2_90_000_200.png
    일양하이트린정 2mg   75 K-003351-020014-036637_0_2_1_2_75_000_200.png
    일양하이트린정 2mg   90 K-003351-020014-036637_0_2_1_2_90_000_200.png
          마도파정  75 K-003351-020014-036637_0_2_1_2_75_000_200.png
          마도파정  90 K-003351-020014-036637_0_2_1_2_90_000_200.png
  로수젯정10/5밀리그램   75 K-003351-020014-036637_0_2_1_2_75_000_200.png
  로수젯정10/5밀리그램   90 K-003351-020014-036637_0_2_1_2_90_000_200.png
```

> **결과**: 뒷면 촬영 12개 (전체 1.6%) — 일양하이트린정·콜리네이트·리바로정·마도파정·로수젯정 5종

---

6. 이미지 시각화

실제 이미지와 바운딩 박스를 함께 시각화하여 데이터 품질을 확인합니다.

샘플 이미지 + 바운딩 박스

K-003483-020877-031885-036637_0_2_0_2_75_000_200.png | 알약 0개



K-003351-016232-019232_0_2_0_2_75_000_200.png | 알약 0개



K-003351-013900-036637_0_2_0_2_75_000_200.png | 알약 0개



K-003351-019232-021325_0_2_0_2_90_000_200.png | 알약 0개



7. 각도별 분석

동일한 약을 70·75·90도로 촬영한 이미지를 비교하고,
각도에 따라 bbox 좌표가 어떻게 달라지는지 수치로 확인합니다.

7-1. 단일 세트 각도별 비교 (랜덤 샘플)

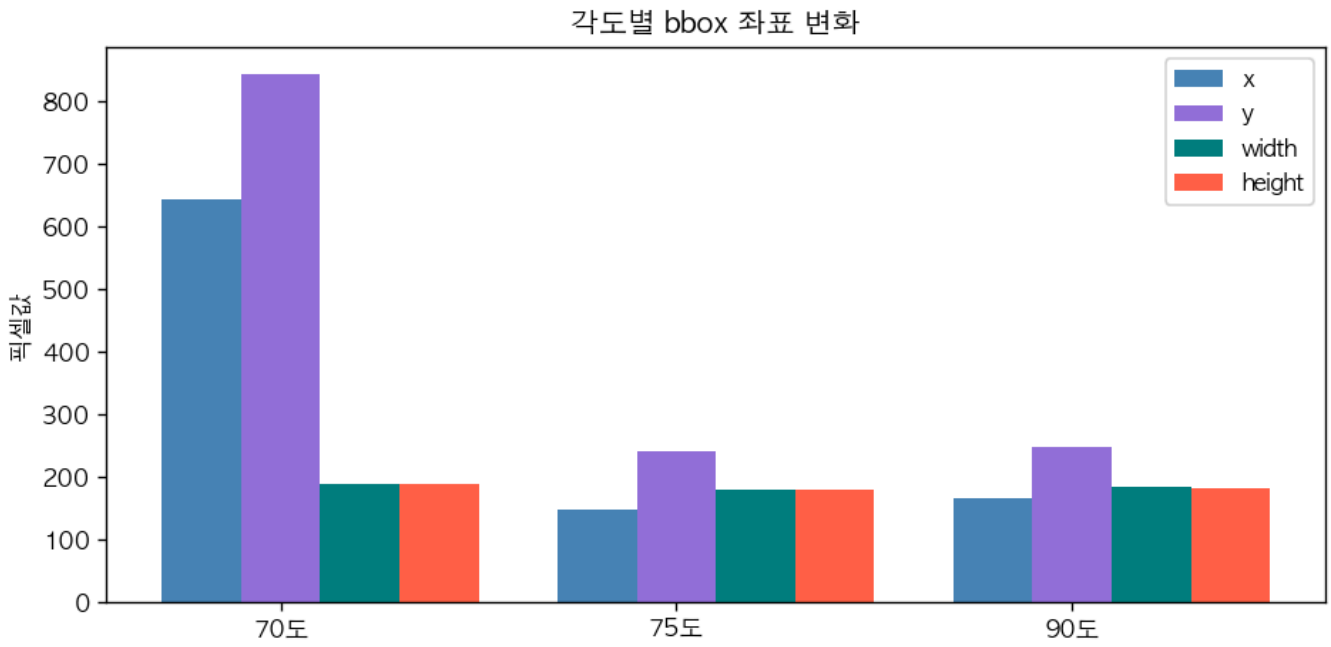


> - 같은 약이라도 각도에 따라 위치·크기·모양이 다르게 보임 → 모델이 각도 변화에 강건해야 함
> - 각인(G40, 515, 387, A7)이 각도별로 선명도가 다름 → 샤프닝 증강 필요

7-2. 각도별 bbox 좌표 변화 (수치 비교)

```
세트      : K-001900-016548-019607-029451_json
약 폴더   : K-001900
JSON 파일: ['K-001900-016548-019607-029451_0_2_0_2_70_000_200.json', 'K-001900-016548-019607-029451_0_2_0_2_75_000_200.json', 'K-001900-016548-019607-029451_0_2_0_2_90_000_200.json']

📐 각도별 bbox 좌표 비교:
 각도   x   y  width  height  area
70도 644 845    189     190 35910
75도 148 241    181     181 32761
90도 167 248    184     182 33488
```



> **결과**: 같은 약이라도 각도가 바뀌면 x·y 좌표가 크게 달라짐 — 위치 기반이 아닌 외형 기반 학습 필요

7-3. 5개 클래스 × 3각도 그리드

5개 클래스 × 3각도 샘플 이미지

보령부스파정 5mg
70도



보령부스파정 5mg
75도



보령부스파정 5mg
90도



가바토파정 100mg
70도



가바토파정 100mg
75도



가바토파정 100mg
90도



스토가정 10mg
70도



스토가정 10mg
75도



스토가정 10mg
90도



레일라정
70도



레일라정
75도



레일라정
90도





> 5개 약종을 70·75·90도로 나란히 비교 — 각도 변화에도 약을 정확히 인식해야 함을 시각적으로 확인

---

8. 메타데이터 분석

JSON에 포함된 약 정보 필드의 채움률을 확인하고
UI 연동 시 활용 가능한 필드를 파악합니다.

8-1. 상위 3개 약 메타데이터 상세

```
분석 대상: ['일양하이트린정 2mg', '기넥신에프정(은행엽엑스)(수출용)', '아토젯정 10/40mg']
```

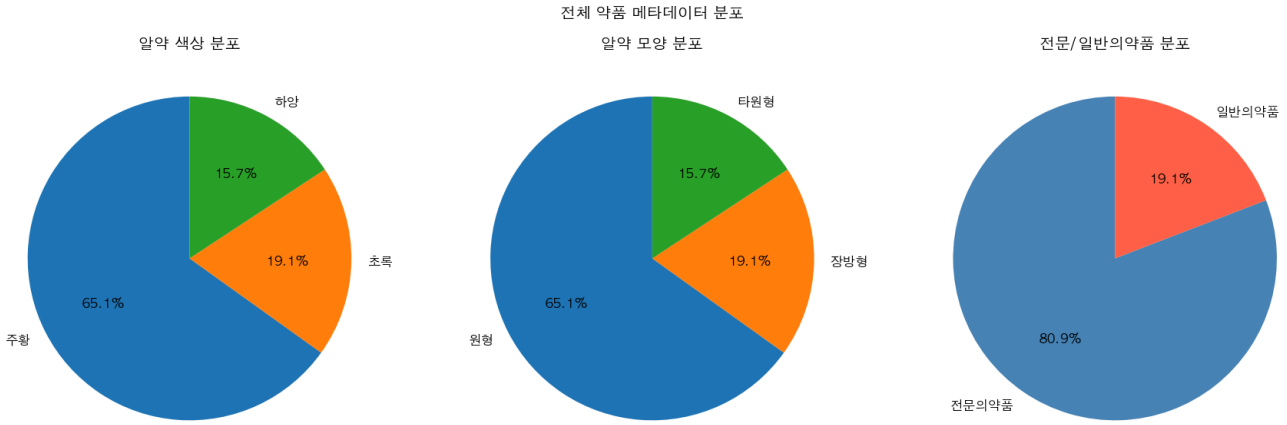
```
📋 상위 3개 약 메타데이터:
```

	0	1	2
약품명	일양하이트린정 2mg	아토젯정 10/40mg	기넥신에프정(은행엽엑스)(수출용)
색상	주황	하양	초록
모양	원형	타원형	장방형
제형	오랜지색 또는 노란색의 원형정제.	백색 내지 미백색의 한 면에 337이 새겨진 양면이 볼록한 캡슐모양의 필름코팅정	진녹색의 타원형 필름 코팅정
앞면 각인	I분할선Y	337	SK
뒷면 각인	HT		G40
분할선 (앞)	-		
분할선 (뒤)			
장축 (mm)	7.01	17.0	11.1
단축 (mm)	7.01	7.0	6.1
두께 (mm)	2.76	7.0	3.9
전문/일반	전문의약품	전문의약품	일반의약품

> | 약품명 | 색상 | 모양 | 앞면 각인 | 뒷면 각인 | 전문/일반 | |---|---|---|---|---|---|---| 일양하이트린정 2mg | 주황 | 원형 | I분할선Y | HT | 전문 | | 아토젯정 10/40mg | 하양 | 타원형 | 337 | — | 전문 | | 기넥신에프정(수출용) | 초록 | 장방형 | SK | G40 | 일반 |

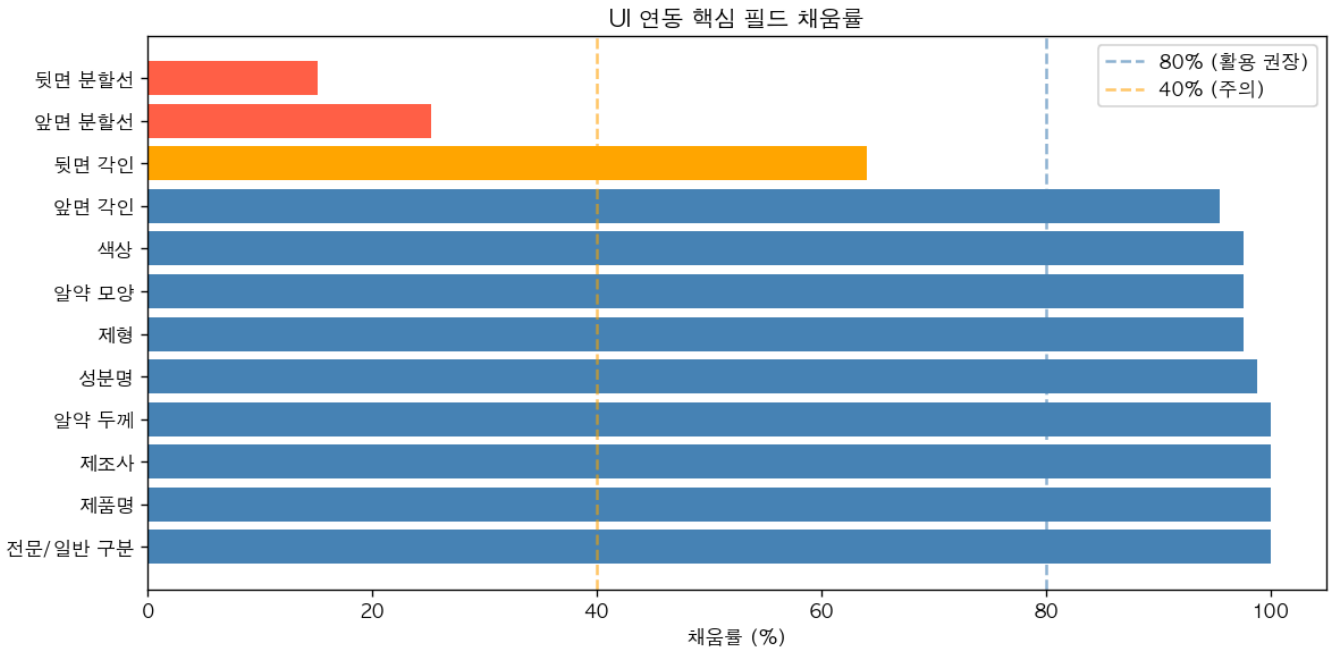
> **UI 활용**: `line_front` 값으로 "처방에 따라 반으로 잘라 드셔도 됩니다" 가이드 제공 가능

8-2. 전체 약품 색상·모양·전문/일반 분포



8-3. UI 연동 핵심 필드 채움률

필드	설명	채움률(%)	UI활용
di_etc_otc_code	전문/일반 구분	100.0	✅
dl_name	제품명	100.0	✅
dl_company	제조사	100.0	✅
thick	알약 두께	100.0	✅
dl_material	성분명	98.8	✅
chart	제형	97.6	✅
drug_shape	알약 모양	97.6	✅
color_class1	색상	97.6	✅
print_front	앞면 각인	95.5	✅
print_back	뒷면 각인	64.1	⚠️
line_front	앞면 분할선	25.3	❌
line_back	뒷면 분할선	15.1	❌

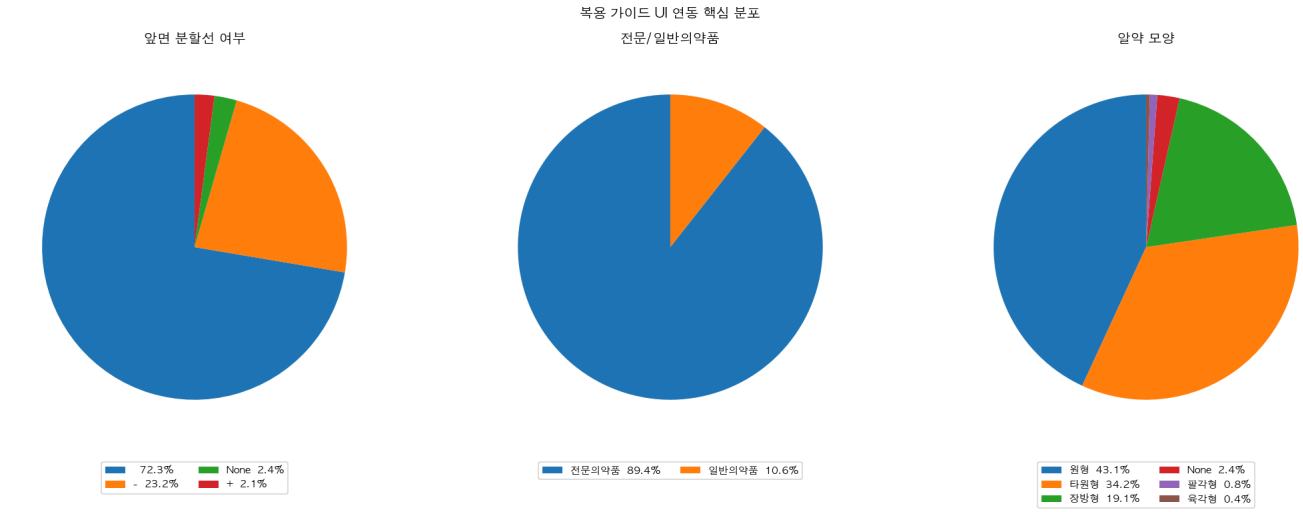


> - ✅ 제품명·제조사·성분명 등 기본 정보 거의 100% → UI 바로 활용 가능
> - ⚠️ 뒷면 각인 64% → 뒷면 촬영 데이터 부족 영향

- ❌ 앞면 분할선 25%, 뒷면 분할선 15% → 분할선 정보 없는 약이 대다수

8-4. 분할선·전문/일반의약품·알약 모양 분포

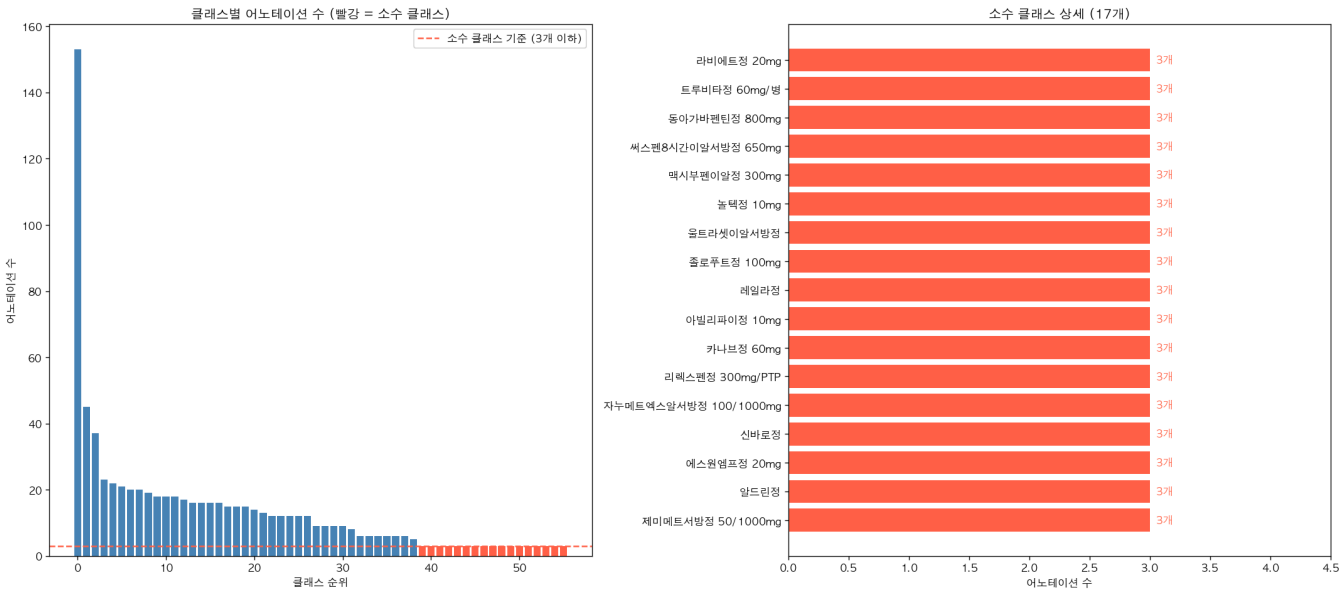
```
분할선 있는 약 비율: 2.1%
→ 복용 가이드 UI: "처방에 따라 반으로 잘라 드셔도 됩니다" 제공 가능
```



---

9. 클래스 불균형 분석

소수 클래스를 파악하고 모델링 팀을 위한 대응 전략을 정리합니다.




```
전체 클래스 수  : 56
소수 클래스 수  : 17 (하위 20%)
최대 불균형 비율: 51배
```

📊 분석 결과

- 전체 클래스: **56개**
- 소수 클래스: **17개** (하위 20%, 어노테이션 3개 이하)
- 최대 불균형: **51배** (일양하이트린정 153개 vs 소수 클래스 3개)

데이터가 특정 클래스에 극도로 편중되어 소수 클래스 약물은 모델이 제대로 학습하기 어렵습니다.

💡 대응 방법 비교

방법	설명	장점	단점
데이터 증강	회전/flip/밝기 조정으로 늘리기	데이터 다양성 확보	원본과 유사한 이미지만 생성
클래스 가중치	소수 클래스에 높은 loss 가중치	구현 간단	다수 클래스 성능 저하 가능
오버샘플링	소수 클래스 이미지 복제	빠른 적용	과적합 위험
언더샘플링	일양하이트린정 153개 → 줄이기	균형 확보	데이터 손실
WeightedRandomSampler	DataLoader에서 소수 클래스 더 자주 샘플링	데이터 손실 없음	학습 속도 저하 가능

> ✅ **권장**: WeightedRandomSampler + 소수 클래스 데이터 증강 병행

---

10. 전처리 전략 및 증강 파이프라인

EDA를 통해 발견한 문제점과 대응 전략을 정리하고
실제 증강 파이프라인을 구현합니다.

10-0. 문제점 요약

#	문제	원인	대응 전략
1	환경 편향	배경 100% 연회색, 조명 100% 주백색	Color Jitter, 배경 합성, 노이즈/블러
2	반쪽 알약 부재	분할선 있는 약은 많지만 실제 반쪽 약 이미지 없음	CoarseDropout
3	각인 선명도 차이	이미지마다 해상도·각도 차이	Sharpening, 1024px 리사이즈
4	클래스 불균형	최대 51배 차이	WeightedRandomSampler, 추가 수집
5	뒷면 데이터 부족	앞면 98.4%, 뒷면 1.6%	뒷면 데이터 추가 수집

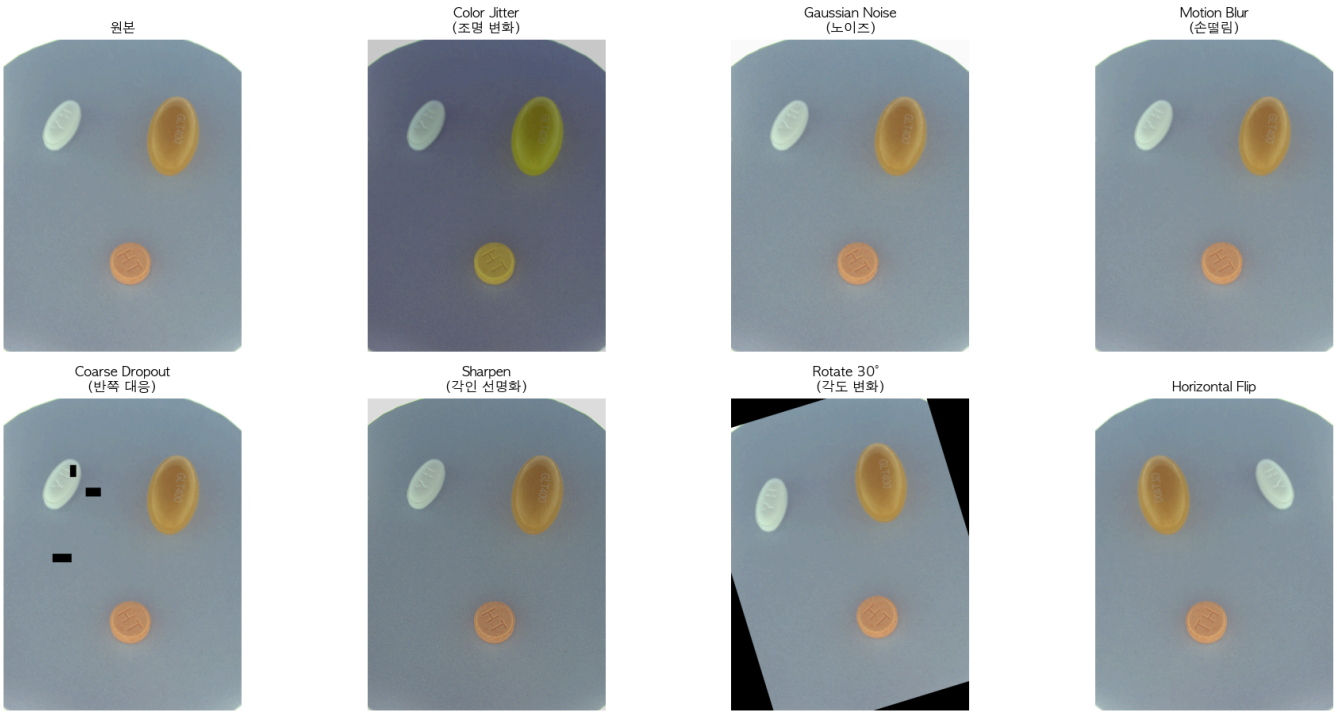
10-1. Albumentations 증강 파이프라인

✅ 증강 파이프라인 정의 완료
`train_transform 단계 수: 11`

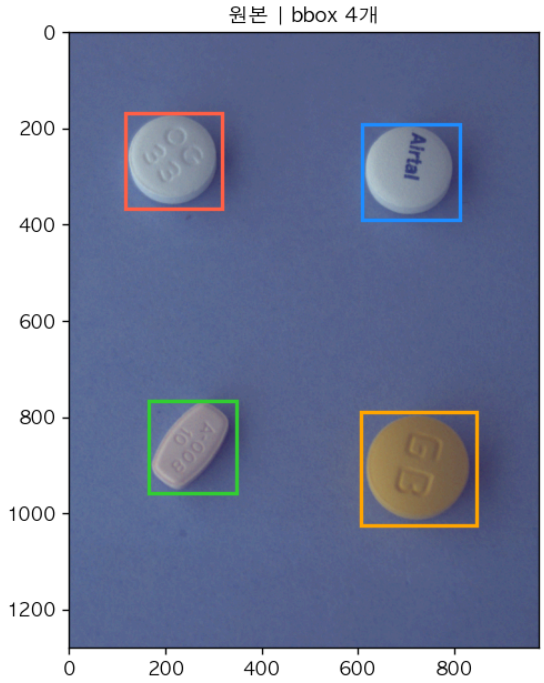
📌 모델링 팀 사용법:
`DataLoader(dataset, batch_size=8, sampler=weighted_sampler)`

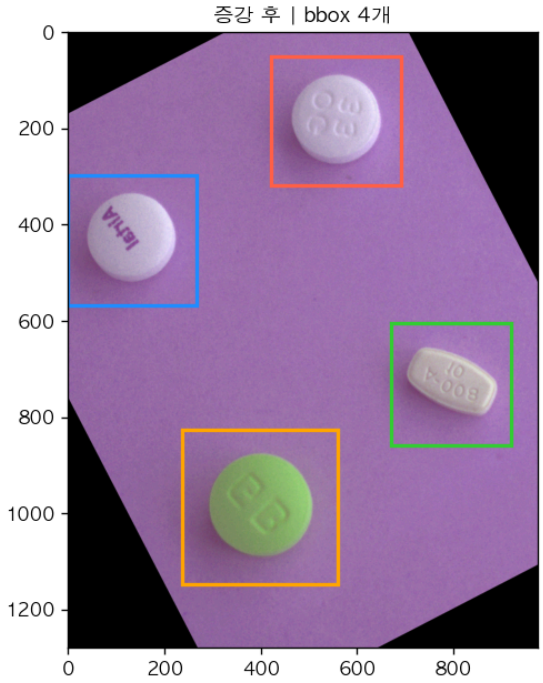
10-2. 증강 기법별 Before / After 비교

증강 기법 비교 | K-003351-018357-021325_0_2_0_2_70_000_200.png



10-3. 증강 후 바운딩 박스 보존 검증





> - 회전·좌우반전·색상 변조 후에도 bbox가 약 위치에 정확히 따라감
> - Color Jitter로 색상이 변해도 bbox 손실 없음 ✅

---

11. 모델링 팀 인계 요약

항목	권장값	근거
입력 해상도	1024 × 1024	mAP@0.75+ 기준, 작은 객체 디테일 보존
정규화	mean=[0.485,0.456,0.406] / std=[0.229,0.224,0.225]	ImageNet 사전학습 기준
Augmentation	`train_transform` 파이프라인 (섹션 10 참고)	환경 편향 + 반쪽 알약 대응
bbox 포맷	COCO (x, y, w, h)	제출 포맷과 동일
min_visibility	0.3	증강 후 잘린 bbox 필터링 기준
클래스 불균형	`WeightedRandomSampler` 적용 권장	최대 51배 불균형 확인

추가 데이터 수집 권장 대상

- 뒷면 촬영 데이터 (현재 1.6%만 존재 — 5종 약물)
- 소수 클래스 17개 약물 (어노테이션 3개 이하)
- 다양한 배경·조명 환경 이미지

```python
# 모델링 팀 DataLoader 연결 예시
from torch.utils.data import DataLoader

train_dataset = PillDataset(ann_df, TRAIN_IMG_DIR,
transform=train_transform)
train_loader  = DataLoader(
    train_dataset,
    batch_size=8,
    sampler=weighted_sampler,  # 클래스 불균형 대응
    num_workers=4
)
```

> 추가 질문은 디스코드 채널에 남겨주세요 🙌